

Numerikus módszerek

12–13. hét – Numerikus integrálás; Szinguláris felbontás és általánosított inverz

Előadásjegyzet

2025/26. tanév, tavaszi félév

Tartalomjegyzék

I. Numerikus integrálás (12. hét)	2
1. Az alapfeladat és motiváció	2
2. Kvadratura formulák általánosan	3
3. Newton–Cotes formulák	4
4. Hibaformulák	6
5. Összetett formulák	9
II. Szinguláris felbontás és általánosított inverz (13. hét)	11
6. Szinguláris felbontás (SVD)	11
7. Az SVD alkalmazása: Eckart–Young-tétel és képtömörítés	13
8. Az általánosított inverz (Moore–Penrose-pseudoinverz)	15
9. Az általánosított inverz approximációs tulajdonsága	17
10. Legkisebb négyzetek módszere	19
11. Az SVD alkalmazása: főkomponens-analízis (PCA)	21

I. rész

Numerikus integrálás (12. hét)

1. Az alapfeladat és motiváció

A feladat

Feladat: Közelítsük a

$$I(f) := \int_a^b f(x) dx$$

Riemann-integrált numerikusan, vagyis véges sok f -értékfelhasználásával.

Miért nem a Riemann-definíció?

A Riemann-integrál definíciója alsó és felső közelítő összegeket (vagy Riemann-összeget) használ. Ha $[a, b]$ -t m egyenlő részre osztjuk, egy tipikus Riemann-összeg

$$R_m(f) = \sum_{k=0}^{m-1} f(\xi_k) \frac{b-a}{m},$$

amelyre $R_m(f) \rightarrow I(f)$, ha $m \rightarrow \infty$. Azonban ez a konvergencia lassú: az f -re tett sima feltételek (például $f \in C^1$) esetén is csak $O(m^{-1})$ sebességgel. Tehát kielégítő pontossághoz sok ($m \gg 1$) tagra lenne szükség, ami számítógépen sok függvényérték-kiértékelést jelent. **Nem gazdaságos.**

Alkalmazási területek

A numerikus integrálás szükséges mindazokban az esetekben, amelyekben az analitikus kiszámítás nem elvégezhető vagy nem kívánatos:

- A primitív függvény *nem állítható elő zárt alakban* (például e^{-x^2} , $\sin(x^2)$, $\cos(x^2)$).
- Az analitikus integrálás elvben elvégezhető, de *rendkívül bonyolult* lenne.
- *Terület, térfogat, ívhossz* kiszámítása, ahol az integrandus mérési adatokból adódik.
- Differenciálegyenletek numerikus módszereinek konstrukciójánál (például Runge–Kutta módszerek, kollokatív módszerek).

Motiváló példák: Számítsuk ki a következő integrálokat!

$$\int_0^1 e^{-x^2} dx = ?, \quad \int_0^\pi \cos(x^2) dx = ?$$

Az első a *Gauss-féle hibaintegrálfüggvény*hez kapcsolódik: a primitív függvény nem elemi. A másodikra szintén nem létezik zárt alakú formula. Mindkettő kiszámítható numerikus integrálással tetszőleges pontossággal.

Az alaptézis: Lagrange-interpoláció + integráció

Ötlet: Helyettesítsük f -et az $x_0 < x_1 < \dots < x_n$ alappontokon épített Lagrange-interpolációs polinomjával $L_n(x) = \sum_{k=0}^n f(x_k) \ell_k(x)$, majd integráljuk az közelített függvényt:

$$\int_a^b f(x) dx \approx \int_a^b L_n(x) dx = \int_a^b \sum_{k=0}^n f(x_k) \ell_k(x) dx = \sum_{k=0}^n f(x_k) \underbrace{\int_a^b \ell_k(x) dx}_{=: A_k}.$$

Az $A_k := \int_a^b \ell_k(x) dx$ *súlyok* csak az alappontoktól (és $[a, b]$ -től) függenek, az f függvénytől *nem*. Ezért elég az alappontokat egyszer rögzíteni, és utána az A_k értékeket előre kiszámítani. A közelítés:

$$\boxed{\int_a^b f(x) dx \approx \sum_{k=0}^n A_k f(x_k).}$$

Megjegyzés: az A_k súlyok kizárólag az alappontoktól függenek, f -től nem. Ebből következik, hogy ha f is polinom (és fokszáma legfeljebb n), a közelítés *pontos*: $L_n = f$, tehát $\int_a^b L_n = \int_a^b f$.

2. Kvadratúra formulák általánosan

2.1. Definíció (Kvadratúra formula). Legyenek $x_0, x_1, \dots, x_n \in [a, b]$ *alappontok* és $A_0, A_1, \dots, A_n \in \mathbb{R}$ *súlyok*. Az

$$Q_n(f) := \sum_{k=0}^n A_k f(x_k)$$

formulát *kvadratúra formulának* nevezzük.

A kvadratúra formula *interpolációs típusú*, ha $A_k = \int_a^b \ell_k(x) dx$ ($k = 0, 1, \dots, n$), ahol ℓ_k a k -adik Lagrange-alappolinom.

2.2. Tétel (Pontossági tétel). Egy Q_n kvadratúra formula interpolációs típusú $\iff$ minden $f \in P_n$ polinomra pontos, azaz

$$\int_a^b f(x) dx = \sum_{k=0}^n A_k f(x_k) \quad \forall f \in P_n.$$

Bizonyítás. ($\Rightarrow$) **Interpolációs típusú $\Rightarrow P_n$ -re pontos.** Ha $f \in P_n$, akkor $L_n(x) = f(x)$ (az interpoláció egyértelműen megadja f -et), tehát

$$Q_n(f) = \sum_{k=0}^n A_k f(x_k) = \int_a^b \sum_{k=0}^n f(x_k) \ell_k(x) dx = \int_a^b L_n(x) dx = \int_a^b f(x) dx.$$

($\Leftarrow$) **P_n -re pontos $\Rightarrow$ interpolációs típusú.** Alkalmazzuk a feltételt az $f = \ell_j$ Lagrange-alappolinomra ($j = 0, 1, \dots, n$). Mivel $\ell_j \in P_n$, a feltétel szerint

$$\int_a^b \ell_j(x) dx = \sum_{k=0}^n A_k \ell_j(x_k) = \sum_{k=0}^n A_k \delta_{jk} = A_j.$$

Tehát $A_j = \int_a^b \ell_j(x) dx$, ami pontosan az interpolációs típus definíciója. □ □

2.3. Megjegyzés. A $Q_n(f) = \sum_{k=0}^n A_k f(x_k)$ formulában összesen $2(n+1)$ szabad paramétert találunk: az $A_0, \dots, A_n$ súlyokat és az $x_0, \dots, x_n$ alappontokat. Az interpolációs típus megkötése rögzíti az A_k -kat (az x_k -k függvényeként), így marad $n+1$ szabad paraméter (az alappontok). Ezek optimális megválasztásával különféle formulatípusok adódnak:

1. **Newton–Cotes típus:** az alappontok egyenletesen osztják fel $[a, b]$ -t.
2. **Csebisev típus:** az összes súly azonos: $A_k \equiv A$.
3. **Gauss típus:** az alappontokat is optimálisan választják, maximalizálva a pontosságot; $2(n+1)$ fokszámig pontos (ez optimális).

A továbbiakban a Newton–Cotes típussal foglalkozunk.

3. Newton–Cotes formulák

Zárt és nyílt formulák

A Newton–Cotes formulákban az alappontok egyenletesen helyezkednek el $[a, b]$ -ben.

- **Zárt formulák** $Z(n)$: a és b is alappont.

$$h = \frac{b-a}{n}, \quad x_k = a + kh, \quad k = 0, 1, \dots, n.$$

- **Nyílt formulák** $Ny(n)$: a és b *nem* alappont.

$$h = \frac{b-a}{n+2}, \quad x_k = a + (k+1)h, \quad k = 0, 1, \dots, n.$$

Az együtthatók meghatározása

A pontossági tétel alapján az A_k értékeket a következő lineáris egyenletrendszer adja meg:

$$\int_a^b x^j dx = \sum_{k=0}^n A_k x_k^j, \quad j = 0, 1, \dots, n.$$

Explicit alakban:

$$\frac{b^{j+1} - a^{j+1}}{j+1} = A_0 x_0^j + A_1 x_1^j + \dots + A_n x_n^j, \quad j = 0, 1, \dots, n.$$

A rendszer mátrixa

$$V^T = \begin{pmatrix} 1 & 1 & \dots & 1 \\ x_0 & x_1 & \dots & x_n \\ \vdots & \vdots & & \vdots \\ x_0^n & x_1^n & \dots & x_n^n \end{pmatrix},$$

azaz a Vandermonde-mátrix transzponáltja; ez nem szinguláris, ha az alappontok különbözők.

Az érintő formula ($Ny(0)$)

A nyílt $n=0$ esetben egyetlen alappont van, a középpont: $x_0 = a + h = a + \frac{b-a}{2} = \frac{a+b}{2}$. A LER egyetlen egyenlete: $A_0 \cdot 1 = b - a$, tehát $A_0 = b - a$.

Érintő formula (középponti szabály, $Ny(0)$):

$$\int_a^b f(x) dx \approx (b-a) \cdot f\left(\frac{a+b}{2}\right) =: E(f).$$

Geometriai értelmezés: a görbe alatti területet azzal a téglalappal közelítjük, amelynek magassága f értéke a középpontban. Ez nem tényleges érintőegyenesre, hanem a középpontban vett vízszintes magasságra támaszkodik. Az „érintő formula” elnevezés történeti okokból maradt használatban; ma gyakran középponti szabálynak nevezzük.

A trapéz formula (Z(1))

A zárt $n = 1$ esetben $x_0 = a$, $x_1 = b$. A LER:

$$A_0 + A_1 = b - a, \quad A_0 \cdot a + A_1 \cdot b = \frac{b^2 - a^2}{2} = \frac{(b-a)(b+a)}{2}.$$

Az első egyenletből $A_0 = b - a - A_1$; visszahelyettesítve: $(b - a - A_1)a + A_1b = \frac{(b-a)(a+b)}{2}$, ami $A_1(b - a) = \frac{(b-a)(a+b)}{2} - a(b - a) = \frac{(b-a)^2}{2}$, tehát $A_1 = \frac{b-a}{2}$. Szimmetria alapján $A_0 = \frac{b-a}{2}$.

Trapéz formula ($Z(1)$):

$$\int_a^b f(x) dx \approx \frac{b-a}{2} \cdot (f(a) + f(b)) =: T(f).$$

Geometriai értelmezés: a görbe alatti területet a $(a, 0)$, $(a, f(a))$, $(b, f(b))$, $(b, 0)$ csúcsú trapéz területével helyettesítjük.

A Simpson formula (Z(2))

A zárt $n = 2$ esetben $x_0 = a$, $x_1 = \frac{a+b}{2}$, $x_2 = b$, $h = \frac{b-a}{2}$. A LER:

$$\begin{aligned} A_0 + A_1 + A_2 &= b - a, \\ A_0a + A_1\frac{a+b}{2} + A_2b &= \frac{b^2 - a^2}{2}, \\ A_0a^2 + A_1\left(\frac{a+b}{2}\right)^2 + A_2b^2 &= \frac{b^3 - a^3}{3}. \end{aligned}$$

Szimmetria alapján $A_0 = A_2$. Az első egyenletből $2A_0 + A_1 = b - a$. A megoldás: $A_0 = A_2 = \frac{b-a}{6}$, $A_1 = \frac{4(b-a)}{6} = \frac{2(b-a)}{3}$.

Simpson formula ($Z(2)$):

$$\int_a^b f(x) dx \approx \frac{b-a}{6} \left(f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right) =: S(f).$$

Megjegyzés: A Simpson-formula a konstrukció alapján P_2 -re pontos. Ennél azonban *erősebb*: P_3 -ra is pontos. Ennek oka a középpontra vett szimmetria. Ha $c = \frac{a+b}{2}$, akkor minden harmadfokú polinom felírható


$$p(x) = \alpha_0 + \alpha_1(x - c) + \alpha_2(x - c)^2 + \alpha_3(x - c)^3$$

alakban. Az $(x - c)$ és $(x - c)^3$ tagok integrálja a szimmetrikus $[c - h, c + h]$ intervallumon nulla, és a Simpson-formula is nullát ad rájuk. A konstans és másodfokú tagokra a formula már

az interpolációs konstrukció miatt pontos. Így a Simpson-formula minden $p \in P_3$ polinomra pontos. Például $p(x) = x^3$ esetén közvetlenül is ellenőrizhető, hogy

$$S(x^3) = \frac{b-a}{6} \left(a^3 + 4 \left(\frac{a+b}{2} \right)^3 + b^3 \right) = \frac{b^4 - a^4}{4} = \int_a^b x^3 dx. \quad \checkmark$$

Az ábrák geometriai szemléltetést nyújtanak:



1. ábra. Az érintő, a trapéz és a Simpson formula szemléltetése ($f(x) = \sin x$, $[0,4; 2,8]$). Az aranyszínű terület a közelítő terület, a kék görbe az eredeti függvény.

4. Hibaformulák

A hibaformulák megadják, mekkora eltérés keletkezik az egzakt és a közelítő integrálérték között. Az alapeszköz az integrálszámítás középértéktétele.

4.1. Tétel (Az integrálszámítás középértéktétele). Ha $f \in C[a, b]$ és $g \in C[a, b]$, továbbá $g(x) \geq 0$ minden $x \in [a, b]$ -re, akkor létezik olyan $\xi \in [a, b]$, hogy

$$\int_a^b f(x) g(x) dx = f(\xi) \int_a^b g(x) dx.$$

Bizonyítás. Legyen $m = \min_{[a,b]} f$ és $M = \max_{[a,b]} f$. Ekkor $m g(x) \leq f(x) g(x) \leq M g(x)$, ezért integrálással

$$m \int_a^b g(x) dx \leq \int_a^b f(x) g(x) dx \leq M \int_a^b g(x) dx.$$

Ha $\int_a^b g(x) dx = 0$, akkor $g \geq 0$ miatt $g \equiv 0$, így az állítás triviális. Ellenkező esetben

$$m \leq \frac{\int_a^b f(x) g(x) dx}{\int_a^b g(x) dx} \leq M.$$

A folytonosság miatt f felveszi az m és M közötti összes értéket, tehát létezik $\xi \in [a, b]$, amelyre

$$f(\xi) = \frac{\int_a^b f(x) g(x) dx}{\int_a^b g(x) dx}.$$

Ebből következik az állítás. □ □

Az érintő formula hibája

4.2. Tétel. Ha $f \in C^2[a, b]$, akkor $\exists \eta \in [a, b]$:

$$\int_a^b f(x) dx - E(f) = \frac{(b-a)^3}{24} f''(\eta).$$

Bizonyítás. Legyen $c = \frac{a+b}{2}$. Taylor tétele szerint minden $x \in [a, b]$ esetén létezik olyan $\xi_x \in [a, b]$, hogy

$$f(x) = f(c) + f'(c)(x-c) + \frac{1}{2}f''(\xi_x)(x-c)^2.$$

Legyen

$$m = \min_{[a,b]} f'', \quad M = \max_{[a,b]} f''.$$

Ekkor minden $x \in [a, b]$ esetén

$$\frac{m}{2}(x-c)^2 \leq f(x) - f(c) - f'(c)(x-c) \leq \frac{M}{2}(x-c)^2.$$

Integrálva, valamint felhasználva, hogy

$$\int_a^b (x-c) dx = 0 \quad \text{és} \quad E(f) = (b-a)f(c),$$

kapjuk:

$$\frac{m}{2} \int_a^b (x-c)^2 dx \leq \int_a^b f(x) dx - E(f) \leq \frac{M}{2} \int_a^b (x-c)^2 dx.$$

Mivel

$$\frac{1}{2} \int_a^b (x-c)^2 dx = \frac{(b-a)^3}{24},$$

ezért

$$m \frac{(b-a)^3}{24} \leq \int_a^b f(x) dx - E(f) \leq M \frac{(b-a)^3}{24}.$$

Mivel f'' folytonos, felvesz minden m és M közötti értéket, ezért létezik $\eta \in [a, b]$, hogy

$$\int_a^b f(x) dx - E(f) = \frac{(b-a)^3}{24} f''(\eta). \quad \square$$

$\square$

A trapéz formula hibája

4.3. Tétel. Ha $f \in C^2[a, b]$, akkor $\exists \eta \in [a, b]$:

$$\int_a^b f(x) dx - T(f) = -\frac{(b-a)^3}{12} f''(\eta).$$

Bizonyítás. Legyen L_1 az f függvény a és b pontokban vett lineáris interpolációs polinomja. Ekkor $T(f) = \int_a^b L_1(x) dx$. A lineáris interpoláció maradéktagja alapján minden $x \in (a, b)$ -re létezik $\xi_x \in (a, b)$, amelyre

$$f(x) - L_1(x) = \frac{f''(\xi_x)}{2}(x-a)(x-b).$$

Mivel $(x-a)(x-b) \leq 0$ az $[a, b]$ intervallumon, a szokásos súlyozott középértékes hibaalakból kapjuk, hogy létezik $\eta \in [a, b]$, amelyre

$$\int_a^b f(x) dx - T(f) = \frac{f''(\eta)}{2} \int_a^b (x-a)(x-b) dx.$$

Az utolsó integrál

$$\int_a^b (x-a)(x-b) dx = - \int_a^b (x-a)(b-x) dx = -\frac{(b-a)^3}{6}.$$

Ezért

$$\int_a^b f(x) dx - T(f) = -\frac{(b-a)^3}{12} f''(\eta). \quad \square$$

$\square$

4.4. Megjegyzés. Az érintő és a trapéz formula hibáját összehasonlítva:

$$\int_a^b f - E(f) \approx \frac{(b-a)^3}{24} f''(\eta), \quad \int_a^b f - T(f) \approx -\frac{(b-a)^3}{12} f''(\eta).$$

Az érintő formula hibája körülbelül *felakkora, és ellentétes előjelű*, mint a trapézé: E -hiba $\approx -\frac{1}{2} \cdot T$ -hiba. Ez az összefüggés a Richardson-extrapoláció alapja: $\frac{2E(f)+T(f)}{3}$ a Simpson-formula!

Valóban: $\frac{1}{3}T(f) + \frac{2}{3}E(f) = \frac{b-a}{6}(f(a) + f(b)) + \frac{2(b-a)}{3}f(c) = S(f)$.

A Simpson formula hibája

4.5. Tétel. Ha $f \in C^4[a, b]$, akkor $\exists \eta \in [a, b]$:

$$\int_a^b f(x) dx - S(f) = -\frac{(b-a)^5}{2880} f^{(4)}(\eta).$$

Bizonyítás. A Simpson-formula minden legfeljebb harmadfokú polinomra pontos, ezért a hiba-funkcionál

$$L(f) := \int_a^b f(x) dx - S(f)$$

eltűnik P_3 -on. A Peano-féle hibatag-tétel szerint, ha $f \in C^4[a, b]$, akkor

$$L(f) = \int_a^b K(t) f^{(4)}(t) dt$$

egy alkalmas Peano-kernellel. A Simpson-formula szimmetriája miatt ez a kernel előjeltartó, így a súlyozott középértéktétel alkalmazható: létezik $\eta \in [a, b]$, amelyre

$$L(f) = f^{(4)}(\eta) L\left(\frac{x^4}{4!}\right).$$

A konstans meghatározásához elegendő az $f(x) = x^4$ esetet kiszámítani. A skálázás miatt feltehetjük, hogy $[a, b] = [-h, h]$. Ekkor

$$\int_{-h}^h x^4 dx = \frac{2h^5}{5}, \quad S(x^4) = \frac{h}{3}(h^4 + 4 \cdot 0 + h^4) = \frac{2h^5}{3}.$$

Tehát

$$L(x^4) = \frac{2h^5}{5} - \frac{2h^5}{3} = -\frac{4h^5}{15}, \quad L\left(\frac{x^4}{4!}\right) = -\frac{h^5}{90}.$$

Mivel $h = \frac{b-a}{2}$,

$$\int_a^b f(x) dx - S(f) = -\frac{h^5}{90} f^{(4)}(\eta) = -\frac{(b-a)^5}{2880} f^{(4)}(\eta). \quad \square$$

□

Összefoglalás: egyszerű formulák hibái

Formula	Hibatag	Pontossági fok
$E(f)$ (érintő)	$+\frac{(b-a)^3}{24} f''(\eta)$	P_1
$T(f)$ (trapéz)	$-\frac{(b-a)^3}{12} f''(\eta)$	P_1
$S(f)$ (Simpson)	$-\frac{(b-a)^5}{2880} f^{(4)}(\eta)$	P_3

5. Összetett formulák

Motiváció: miért szükségesek?

A hibák $(b-a)^3$ -ra illetve $(b-a)^5$ -re arányosak. Ha $[a, b]$ nagy, a hiba is nagy lehet. A megoldás: *osszuk fel $[a, b]$ -t sok kis részre*, és minden részintervallumon alkalmazzuk az egyszerű formulát. Az összeg teljes hibáját a kis részhibák összege adja.

A trapéz összetett formula

Osszuk fel $[a, b]$ -t m egyenlő részre: $h = \frac{b-a}{m}$, $x_k = a + kh$ ($k = 0, 1, \dots, m$). Alkalmazzuk a trapéz formulát minden $[x_{k-1}, x_k]$ részintervallumon:

$$\int_{x_{k-1}}^{x_k} f \approx \frac{h}{2} (f(x_{k-1}) + f(x_k)).$$

Összegezve $k = 1, \dots, m$ -re, és felhasználva, hogy a belső pontok $(x_1, \dots, x_{m-1})$ kétszer jelennek meg:

Trapéz összetett formula (trapéz szabály):

$$\int_a^b f(x) dx \approx T_m(f) := \frac{b-a}{2m} \left(f(a) + 2 \sum_{k=1}^{m-1} f(x_k) + f(b) \right).$$

Az együtthatósorozat: $1, 2, 2, \dots, 2, 1$.

5.1. Tétel (A trapéz összetett formula hibája). Ha $f \in C^2[a, b]$, akkor $\exists \eta \in [a, b]$:

$$\int_a^b f(x) dx - T_m(f) = -\frac{(b-a)^3}{12m^2} f''(\eta).$$

Bizonyítás. Az i -edik részintervallumon ($i = 1, \dots, m$) a trapéz hiba $-\frac{h^3}{12}f''(\eta_i)$, ahol $h = \frac{b-a}{m}$ és $\eta_i \in [x_{i-1}, x_i]$. Összegezve:

$$\int_a^b f - T_m(f) = -\frac{h^3}{12} \sum_{i=1}^m f''(\eta_i).$$

Mivel f'' folytonos, a véges sok érték számtani közepe is f'' minimuma és maximuma közé esik; ezért létezik $\eta \in [a, b]$, amelyre

$$\frac{1}{m} \sum_{i=1}^m f''(\eta_i) = f''(\eta).$$

Így

$$\int_a^b f - T_m(f) = -\frac{mh^3}{12}f''(\eta) = -\frac{(b-a)^3}{12m^2}f''(\eta). \quad \square$$

$\square$

A Simpson összetett formula

A Simpson formula páros m -t igényel ($m = 2s$, $s \in \mathbb{N}$). Ekkor $[a, b]$ -t m egyenlő részre osztjuk ($h = \frac{b-a}{m}$), majd a $[x_{2k-2}, x_{2k}]$ ($k = 1, \dots, m/2$) részintervallumokon – amelyek szélessége $2h$ – alkalmazzuk a Simpson formulát.

Simpson összetett formula (Simpson szabály):

$$S_m(f) := \frac{b-a}{3m} \left(f(a) + 4 \sum_{k=1}^{m/2} f(x_{2k-1}) + 2 \sum_{k=1}^{m/2-1} f(x_{2k}) + f(b) \right).$$

Az együtthatósorozat: 1, 4, 2, 4, 2, $\dots$, 4, 2, 4, 1.

5.2. Tétel (A Simpson összetett formula hibája). Ha $f \in C^4[a, b]$, akkor $\exists \eta \in [a, b]$:

$$\int_a^b f(x) dx - S_m(f) = -\frac{(b-a)^5}{180m^4} f^{(4)}(\eta).$$

Bizonyítás. Az egyes Simpson-panelek szélessége $2h$, ahol $h = \frac{b-a}{m}$. Az i -edik panelen a Simpson-hiba $-\frac{(2h)^5}{2880}f^{(4)}(\eta_i)$ valamely panelbeli η_i -re. Összesen $m/2$ panel van, ezért

$$\int_a^b f - S_m(f) = -\frac{(2h)^5}{2880} \sum_{i=1}^{m/2} f^{(4)}(\eta_i).$$

A $f^{(4)}$ folytonossága miatt a véges sok érték átlaga felvehető egy $\eta \in [a, b]$ pontban, így


$$\int_a^b f - S_m(f) = -\frac{m}{2} \cdot \frac{32h^5}{2880} f^{(4)}(\eta) = -\frac{16mh^5}{2880} f^{(4)}(\eta) = -\frac{(b-a)^5}{180m^4} f^{(4)}(\eta). \quad \square$$

$\square$

5.3. Megjegyzés.

1. Ha $f \in C^2[a, b]$, akkor $T_m(f) \rightarrow I(f)$, és a konvergencia m^2 rendű.

2. Ha $f \in C^4[a, b]$, akkor $S_m(f) \rightarrow I(f)$, és a konvergencia m^4 rendű.
3. A Simpson összegzett formula tehát lényegesen gyorsabban konvergál, mint a trapéz.
4. Az érintő formulából is képezhető összetett formula; hibája szintén $O(m^{-2})$, de az előjele ellentétes a trapézéval.



2. ábra. Az összetett trapéz formula $m = 1, 2, 4, 8$ résszel ($f(x) = \sin x$, $[0, \pi]$). Az arany színű terület a közelítő, a kék görbe az egzakt függvény.

Szám példa. Közelítsük az $\int_0^1 e^{-x^2} dx$ integrált $m = 4$ résszel, a trapéz és a Simpson összetett formulájával!

Az osztópontok: $h = 0,25$; $x_k = 0; 0,25; 0,5; 0,75; 1,0$. Függvényértékek: $f_k = e^{-x_k^2}$:

$$f_0 = 1,00000, \quad f_1 = 0,93941, \quad f_2 = 0,77880, \quad f_3 = 0,57007, \quad f_4 = 0,36788.$$

Trapéz ($m = 4$): $T_4 = \frac{0,25}{2}(f_0 + 2f_1 + 2f_2 + 2f_3 + f_4) = \frac{1}{8}(1 + 2 \cdot 0,93941 + 2 \cdot 0,77880 + 2 \cdot 0,57007 + 0,36788) = \frac{1}{8} \cdot 5,94444 \approx 0,74306$.

Simpson ($m = 4$): $S_4 = \frac{0,25}{3}(f_0 + 4f_1 + 2f_2 + 4f_3 + f_4) = \frac{1}{12}(1 + 4 \cdot 0,93941 + 2 \cdot 0,77880 + 4 \cdot 0,57007 + 0,36788) \approx 0,74683$.

A pontos érték (12 jegy): $0,74682413\dots$ Hiba: T_4 -nél $\approx 3,8 \cdot 10^{-3}$, S_4 -nél $\approx 7 \cdot 10^{-7}$. A Simpson formula négy részre osztva is több nagyságrenddel pontosabb!

II. rész

Szinguláris felbontás és általánosított inverz (13. hét)

6. Szinguláris felbontás (SVD)

Motiváció

Hermite-féle (valós esetben szimmetrikus) $A \in \mathbb{C}^{n \times n}$ mátrix esetén az $A = UDU^*$ spektrális felbontás létezik, ahol U unitér és $D = \text{diag}(\lambda_1, \dots, \lambda_n)$. Ez azt fejezi ki: A az $u_1, \dots, u_n$ ortonormált bázis vektorait sajátvektorokként kezeli, azaz $Au_i = \lambda_i u_i$.

Nem szimmetrikus esetben ez általában nem lehetséges. Azonban azt elérhetjük, hogy A az $\mathbb{R}^n$ egy ortonormált bázisát $(v_1, \dots, v_r)$ $\mathbb{R}^m$ egy másik ortonormált rendszerébe $(u_1, \dots, u_r)$ vigye,

$\sigma_i > 0$ skalárok segítségével: $Av_i = \sigma_i u_i$.

6.1. Tétel (Szinguláris felbontás). Tetszőleges $A \in \mathbb{C}^{m \times n}$ mátrixhoz $\exists U \in \mathbb{C}^{m \times m}$ és $V \in \mathbb{C}^{n \times n}$ unitér mátrix, valamint $D \in \mathbb{C}^{m \times n}$ mátrix, amelyre

$$A = UDV^*,$$

ahol

$$D = \begin{pmatrix} \Sigma & 0 \\ 0 & 0 \end{pmatrix}, \quad \Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r), \quad \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0,$$

és $r = \text{rang}(A)$.

*Bizonyítás. Az A^*A mátrix vizsgálata.* $A^*A \in \mathbb{C}^{n \times n}$ Hermite-mátrix $((A^*A)^* = A^*(A^*)^* = A^*A)$ és pozitív szemidefinit: $x^*(A^*A)x = (Ax)^*(Ax) = \|Ax\|^2 \geq 0$. Ezért A^*A unitéren diagonalizálható: $A^*A = V\Lambda V^*$, ahol V unitér és $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$, $\lambda_1 \geq \dots \geq \lambda_n \geq 0$.

A nullánál nagyobb sajátértékek száma $r = \text{rang}(A^*A) = \text{rang}(A)$.

A szinguláris értékek. Legyen $\sigma_i = \sqrt{\lambda_i} > 0$ ($i = 1, \dots, r$), és legyenek $v_1, \dots, v_n$ V unitér mátrix oszlopai (A^*A ortonormált sajátvektorai).

A bal szinguláris vektorok meghatározása. Defináljuk: $u_i := \frac{Av_i}{\sigma_i}$ ($i = 1, \dots, r$). Ellenőrizzük az ortogonalitást: $i \neq j$ esetén

$$\langle u_i, u_j \rangle = \frac{1}{\sigma_i \sigma_j} \langle Av_i, Av_j \rangle = \frac{1}{\sigma_i \sigma_j} v_i^* (A^*A) v_j = \frac{\lambda_j}{\sigma_i \sigma_j} \langle v_i, v_j \rangle = 0.$$

Ugyanígy $\|u_i\|^2 = \frac{1}{\sigma_i^2} \|Av_i\|^2 = \frac{\lambda_i}{\sigma_i^2} = 1$. Tehát $u_1, \dots, u_r$ ortonormált rendszer. Egészítsük ki $\mathbb{C}^m$ ortonormált bázisává: $u_1, \dots, u_m$.

Az $A = UDV^*$ egyenlet igazolása. $AV = A[v_1 \mid \dots \mid v_n] = [\sigma_1 u_1 \mid \dots \mid \sigma_r u_r \mid 0 \mid \dots \mid 0] = U D$, ezért $A = U D V^*$ (jobb oldalon V^* -gal szorzunk, mivel V unitér). $\square$ $\square$

6.2. Definíció (Szinguláris értékek). Az $A \in \mathbb{C}^{m \times n}$ mátrix szinguláris felbontásában a $\sigma_1, \dots, \sigma_r > 0$ értékeket az A szinguláris értékeinek nevezzük. Felírhatók mint

$$\sigma_i = \sqrt{\lambda_i(A^*A)} > 0, \quad i = 1, \dots, r.$$

A v_i vektorokat *jobb szinguláris vektoroknak*, az u_i vektorokat *bal szinguláris vektoroknak* nevezzük.

6.3. Definíció (Redukált SVD). Legyen $A \in \mathbb{C}^{m \times n}$ és $r = \text{rang}(A)$. A teljes SVD-ben csak a pozitív szinguláris értékekhez tartozó oszlopokat megtartva legyen

$$U_r = [u_1 \mid \dots \mid u_r] \in \mathbb{C}^{m \times r}, \quad V_r = [v_1 \mid \dots \mid v_r] \in \mathbb{C}^{n \times r},$$

és

$$\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{C}^{r \times r}.$$

Ekkor

$$\boxed{A = U_r \Sigma_r V_r^*}$$

az A redukált SVD-je. Az U_r és V_r mátrixok oszlopai ortonormáltak, de általában nem négyzetes unitér mátrixok. A redukált alak ugyanazt az A mátrixot adja vissza, mint

a teljes SVD; csak a nullához tartozó, információt nem hordozó oszlopokat és blokkokat hagyja el.

6.4. Megjegyzés.

1. $A^*A \in \mathbb{C}^{n \times n}$ és $AA^* \in \mathbb{C}^{m \times m}$ pozitív sajátértékei *azonosak*: ha $A^*Av = \lambda v$, akkor $AA^*(Av) = \lambda(Av)$.
2. A^*A sajátvektorai a V unitér mátrix oszlopai (jobb szinguláris vektorok).
3. AA^* sajátvektorai az U unitér mátrix oszlopai (bal szinguláris vektorok).
4. $m = n$ esetén: $\sigma_1 = \|A\|_2$ (indukált 2-norma) és $\|A\|_F^2 = \sum_{i=1}^r \sigma_i^2$ (Frobenius-norma).

6.5. Tétel (Lineáris transzformáció jellemzése). Ha $\text{rang}(A) = r$, akkor

$$\ker(A) = \text{span}\{v_{r+1}, \dots, v_n\}, \quad \text{Im}(A) = \text{span}\{u_1, \dots, u_r\}.$$

Bizonyítás. Ker: Ha $v \in \ker(A)$, akkor $A^*Av = 0$, azaz v a nulla sajátértékhez tartozó sajátvektor: $v \in \text{span}\{v_{r+1}, \dots, v_n\}$. Megfordítva: $Av_j = 0$ minden $j > r$ -re, mert $\|Av_j\|^2 = \lambda_j = 0$.

Im: $\text{Im}(A) = \text{span}\{Av_1, \dots, Av_r\} = \text{span}\{\sigma_1 u_1, \dots, \sigma_r u_r\} = \text{span}\{u_1, \dots, u_r\}$. $\square \quad \square$

Alkalmazási területek

1. **Többváltozós statisztika:** a szóródási mátrix vizsgálata, varianciák tömörítése (főkomponens-analízis, PCA).
2. **Dokumentumkeresés és tematizálás:** nagy adatbázisokban latens szemantikus analízis (LSA), adatbányászat.
3. **Jelfeldolgozás:** képtömörítés, zajszűrés, alacsony rangú közelítések.
4. **Geofizika:** mérési adatok inverziója, tomográfia.

7. Az SVD alkalmazása: Eckart–Young-tétel és képtömörítés

Alacsony rangú közelítés

Az SVD egyik legfontosabb alkalmazása az, hogy az A mátrixot alacsony rangú mátrixokkal közelítjük. Az Eckart–Young-tétel azt mondja ki, hogy az első k szinguláris tag megtartása optimális közelítést ad.

7.1. Tétel (Eckart–Young). Legyen $\text{rang}(A) = r$ és $0 \leq k < r$; továbbá $A_k = \sum_{i=1}^k \sigma_i u_i v_i^*$ ($A_0 = 0$). Ekkor A_k az A legjobb rangfeljebb- k közelítése a 2-normában és a Frobenius-normában egyaránt:

$$\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^r \sigma_i^2}, \quad \|A - A_k\|_2 = \sigma_{k+1}.$$

Vagyis minden $\text{rang}(B) \leq k$ mátrixra

$$\|A - B\|_2 \geq \sigma_{k+1}, \quad \|A - B\|_F \geq \sqrt{\sum_{i=k+1}^r \sigma_i^2}.$$

Bizonyítás. Miért ilyen alakú az A_k ? A redukált SVD alakja

$$A = U_r \Sigma_r V_r^*,$$

ahol

$$U_r = [u_1 \mid \cdots \mid u_r], \quad \Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r), \quad V_r = [v_1 \mid \cdots \mid v_r].$$

A diagonális Σ_r mátrixszal való szorzás az U_r oszlopait skálázza:

$$U_r \Sigma_r = [\sigma_1 u_1 \mid \sigma_2 u_2 \mid \cdots \mid \sigma_r u_r],$$

míg

$$V_r^* = \begin{pmatrix} v_1^* \\ v_2^* \\ \vdots \\ v_r^* \end{pmatrix}.$$

Ezért a blokkos mátrixszorzás szabálya szerint

$$A = [\sigma_1 u_1 \mid \cdots \mid \sigma_r u_r] \begin{pmatrix} v_1^* \\ \vdots \\ v_r^* \end{pmatrix} = \sum_{i=1}^r \sigma_i u_i v_i^*.$$

Itt fontos, hogy u_i és v_i általában különböző dimenziós terekben élnek:

$$u_i \in \mathbb{C}^m, \quad v_i \in \mathbb{C}^n.$$

Ez nem gond, mert $u_i v_i^*$ *nem belső szorzat*, hanem külső szorzat:

$$u_i \in \mathbb{C}^{m \times 1}, \quad v_i^* \in \mathbb{C}^{1 \times n}, \quad u_i v_i^* \in \mathbb{C}^{m \times n}.$$

Tehát $u_i v_i^*$ ugyanolyan méretű mátrix, mint A . Elemenként

$$(u_i v_i^*)_{pq} = (u_i)_p \overline{(v_i)_q}, \quad p = 1, \dots, m, \quad q = 1, \dots, n.$$

Ez rang-1 mátrix: egy $x \in \mathbb{C}^n$ vektorból először a v_i irányú komponenst veszi ki a $v_i^* x$ számmal, majd ezt az $u_i \in \mathbb{C}^m$ irányba teszi át:

$$(u_i v_i^*)x = u_i (v_i^* x) \in \mathbb{C}^m.$$

A σ_i szinguláris érték ennek a komponensnek a skálázása.

Ha csak az első k tagot tartjuk meg, akkor

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^*.$$

Ez valóban rang- k mátrix: $j \leq k$ esetén $A_k v_j = \sigma_j u_j$, míg $j > k$ esetén $A_k v_j = 0$, ezért

$$\text{Im}(A_k) = \text{span}\{u_1, \dots, u_k\},$$

és így $\text{rang}(A_k) = k$ ($A_0 = 0$ esetén a rang 0).

A hiba nagysága. Először vegyük észre, hogy $A - A_k = \sum_{i=k+1}^r \sigma_i u_i v_i^*$, ezért

$$\|A - A_k\|_2 = \sigma_{k+1}, \quad \|A - A_k\|_F = \sqrt{\sum_{i=k+1}^r \sigma_i^2}.$$

A 2-normás optimalitáshoz legyen B tetszőleges, $\text{rang}(B) \leq k$ mátrix, és $W = \ker(B)$. Ekkor $\dim(W) \geq n - k$. A $V_{k+1} = \text{span}\{v_1, \dots, v_{k+1}\}$ altér dimenziója $k+1$, ezért $W \cap V_{k+1}$ tartalmaz nemnulla vektort. Válasszunk benne egységvektort: $w = \sum_{i=1}^{k+1} c_i v_i$, $\sum |c_i|^2 = 1$. Mivel $Bw = 0$,

$$\|A - B\|_2 \geq \|(A - B)w\|_2 = \|Aw\|_2 = \left\| \sum_{i=1}^{k+1} c_i \sigma_i u_i \right\|_2 = \sqrt{\sum_{i=1}^{k+1} |c_i|^2 \sigma_i^2} \geq \sigma_{k+1}.$$

A Frobenius-normás optimalitás a Mirsky-tétel speciális esete: a Frobenius-norma unitér invarianciája miatt a legjobb rangfeljebb- k közelítés hibája pontosan a levágott szinguláris értékek négyzetösszegének gyöke. Ezt az A_k mátrix eléri, tehát a megadott alsó korlát éles. $\square \quad \square$

Alkalmazás: képtömörítés

Egy szürkeárnyaltos pixelkép reprezentálható mint $A \in \mathbb{R}^{m \times n}$ mátrix, ahol a_{ij} a (i, j) pixel intenzitása. Az SVD felbontás után:

- Az A_k rang- k közelítés *tömörített* képet ad: tároláshoz $k(m + n)$ szám kell (az σ_i , u_i , v_i adatok), szemben az eredeti mn -nel.
- A tömörítési arány akkor jó, ha a szinguláris értékek gyorsan csökkennek (néhány nagy dominálja a többi).
- A Frobenius-hiba: $\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^r \sigma_i^2}$, amely a pixelenkénti négyzethibát méri.



3. ábra. SVD-alapú alacsony rangú közelítés a *kuty.PNG* képen, RGB-csatornánként alkalmazva. Bal: az eredeti kép. Közép: rang- $r/2$ közelítés. Jobb: rang-10 közelítés.

8. Az általánosított inverz (Moore–Penrose-pseudoinverz)

Motiváció

Ha $A \in \mathbb{C}^{m \times n}$ nem négyzetes ($m \neq n$), vagy négyzetes de szinguláris, akkor az $Ax = b$ LER általában nem oldható meg klasszikus értelemben. Keresünk egy „legjobb közelítő megoldást”, amelyet az A^+ pszeudoinverz segítségével írhatunk fel.

8.1. Definíció (Moore–Penrose-féle általánosított inverz). Az $A \in \mathbb{C}^{m \times n}$ mátrix *általánosított (pszeudo-) inverze* az $A^+ \in \mathbb{C}^{n \times m}$ mátrix, ha a következő négy *Moore–Penrose-feltétel* teljesül:

1. AA^+ önadjungált: $(AA^+)^* = AA^+$,
2. A^+A önadjungált: $(A^+A)^* = A^+A$,
3. $AA^+A = A$,
4. $A^+AA^+ = A^+$.

8.2. Tétel. Az A^+ általánosított inverz *egyértelmű*.

Bizonyítás. Tegyük fel, hogy B és C is teljesíti a Moore–Penrose-feltételeket A -ra. Megmutatjuk, hogy $B = C$.

Az AB mátrix önadjungált és idempotens, mert

$$(AB)^* = AB, \quad (AB)^2 = ABAB = (ABA)B = AB.$$

Továbbá $\text{Im}(AB) = \text{Im}(A)$, hiszen $\text{Im}(AB) \subseteq \text{Im}(A)$, míg $ABA = A$ miatt $\text{Im}(A) \subseteq \text{Im}(AB)$. Ezért AB az $\text{Im}(A)$ -ra vett ortogonális projekció. Ugyanez igaz AC -re is, tehát az ortogonális projekció egyértelműsége miatt

$$AB = AC =: P.$$

Hasonlóan BA és CA önadjungált idempotensek. Ráadásul

$$\ker(BA) = \ker(A),$$

mert $Ax = 0$ esetén nyilván $BAx = 0$, míg $BAx = 0$ esetén $Ax = ABAx = 0$. Így BA és CA ugyanarra az $\ker(A)^\perp = \text{Im}(A^*)$ altérre vetítenek ortogonálisan, tehát

$$BA = CA =: Q.$$

Most bontsunk fel egy tetszőleges $y \in \mathbb{C}^m$ vektort az $\mathbb{C}^m = \text{Im}(A) \oplus \text{Im}(A)^\perp$ ortogonális felbontás szerint: $y = y_R + y_N$. Mivel $P = AB = AC$ az $\text{Im}(A)$ -ra vett ortogonális projekció, $Py_N = 0$, és

$$By_N = BABy_N = B(AB)y_N = 0, \quad Cy_N = CACy_N = C(AC)y_N = 0.$$

Ha pedig $y_R \in \text{Im}(A)$, akkor $y_R = Ax$ valamely x -re, és

$$By_R = BAx = Qx = CAx = Cy_R.$$

Tehát $By = Cy$ minden y -ra, vagyis $B = C$. □ □

A pszeudoinverz előállítás

8.3. Tétel (Diagonális mátrix pszeudoinverze). Legyen $D \in \mathbb{C}^{m \times n}$ diagonális (d_{ii} -kkel). Ekkor $D^+ \in \mathbb{C}^{n \times m}$ szintén diagonális:

$$d_{ii}^+ = \begin{cases} 1/d_{ii}, & d_{ii} \neq 0, \\ 0, & d_{ii} = 0. \end{cases}$$

Bizonyítás. Ellenőrizzük az 1–4 feltételeket.

1. $(DD^+)_{ii} = d_{ii} \cdot d_{ii}^+ \in \{0, 1\}$; valós, tehát $(DD^+)^* = DD^+$. ✓
2. Hasonlóan $(D^+D)^* = D^+D$. ✓
3. $(DD^+D)_{ii} = d_{ii} \cdot d_{ii}^+ \cdot d_{ii} = d_{ii}$. ✓
4. $(D^+DD^+)_{ii} = d_{ii}^+ \cdot d_{ii} \cdot d_{ii}^+ = d_{ii}^+$. ✓

□

□

8.4. Tétel (Az általánosított inverz előállítása SVD-vel). Legyen $A = UDV^*$ az A szinguláris felbontása. Ekkor:

$$A^+ = VD^+U^*,$$

ahol D^+ a Tétel 8.3 szerinti pszeudoinverz.

Bizonyítás. Legyen $B = VD^+U^*$. Igazoljuk az 1–4 feltételeket:

1. $AB = UDV^* \cdot VD^+U^* = U(DD^+)U^*$; ez önadjungált, mert DD^+ önadjungált (Tétel 8.3).
2. $BA = VD^+U^* \cdot UDV^* = V(D^+D)V^*$; szintén önadjungált.
3. $ABA = UDV^*VD^+U^*UDV^* = U(DD^+D)V^* = UDV^* = A$.
4. $BAB = VD^+U^*UDV^*VD^+U^* = V(D^+DD^+)U^* = VD^+U^* = B$. ✓

□

□

Speciális esetek

8.5. Tétel (Túlhatározott, teljes rangú eset). Legyen $A \in \mathbb{C}^{m \times n}$, $m > n$ és $\text{rang}(A) = n$ (teljes oszloprangú). Ekkor:

$$A^+ = (A^*A)^{-1}A^*.$$

Bizonyítás. Használjuk a redukált SVD-t: $A = U_1\Sigma V^*$, ahol $U_1 \in \mathbb{C}^{m \times n}$ ortonormált oszlopú mátrix, $V \in \mathbb{C}^{n \times n}$ unitér, és $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$ invertálható. Ekkor

$$A^+ = V\Sigma^{-1}U_1^*.$$

Másrészt

$$A^*A = V\Sigma U_1^*U_1\Sigma V^* = V\Sigma^2V^*;$$

így

$$(A^*A)^{-1}A^* = V\Sigma^{-2}V^*V\Sigma U_1^* = V\Sigma^{-1}U_1^* = A^+. \quad \square$$

□

8.6. Tétel (Alulhatározott, teljes rangú eset). Legyen $A \in \mathbb{C}^{m \times n}$, $m < n$ és $\text{rang}(A) = m$ (teljes sorrangú). Ekkor:

$$A^+ = A^*(AA^*)^{-1}.$$

Bizonyítás. Használjuk a redukált SVD-t: $A = U\Sigma V_1^*$, ahol $U \in \mathbb{C}^{m \times m}$ unitér, $V_1 \in \mathbb{C}^{n \times m}$ ortonormált oszlopú mátrix, és $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_m)$ invertálható. Ekkor

$$A^+ = V_1\Sigma^{-1}U^*.$$

Másrészt

$$AA^* = U\Sigma V_1^*V_1\Sigma U^* = U\Sigma^2U^*;$$

így

$$A^*(AA^*)^{-1} = V_1\Sigma U^*U\Sigma^{-2}U^* = V_1\Sigma^{-1}U^* = A^+. \quad \square$$

□

9. Az általánosított inverz approximációs tulajdonsága

9.1. Definíció (Általánosított megoldás). Az $Ax = b$ LER általánosított megoldása:

$$x^+ := A^+b.$$

Következmények a speciális esetekben

- **Túlhatározott, teljes rangú eset** ($m > n$, $\text{rang}(A) = n$):

$$x^+ = (A^*A)^{-1}A^*b \iff A^*Ax^+ = A^*b.$$

Az $A^*Ax = A^*b$ egyenletrendszert *Gauss-féle normálegyenleteknek* nevezzük. x^+ a *legkisebb négyzetek megoldása* (minimalizálja $\|Ax - b\|_2$ -t).

- **Alulhatározott, teljes rangú eset** ($m < n$, $\text{rang}(A) = m$):

$$x^+ = A^*(AA^*)^{-1}b.$$

Ha $y := (AA^*)^{-1}b$, akkor $Ax^+ = AA^*y = b$, azaz x^+ valódi megoldás. Ráadásul x^+ az összes megoldás közül a *minimális normájú*.

9.2. Tétel (Approximációs tulajdonság). Legyenek $A \in \mathbb{C}^{m \times n}$ és $b \in \mathbb{C}^m$ adottak, $x^+ = A^+b$.

1. $\|Ax - b\|_2 \geq \|Ax^+ - b\|_2 \quad \forall x \in \mathbb{C}^n$ (azaz x^+ minimalizálja a maradékot).
2. Ha $H := \{x \in \mathbb{C}^n : \|Ax - b\|_2 = \|Ax^+ - b\|_2\}$ az összes minimalizáló halmaza, akkor $\|x^+\|_2 < \|x\|_2 \quad \forall x \in H, x \neq x^+$ (azaz x^+ minimális normájú a minimalizálók között).

Bizonyítás. **1. állítás.** A Moore–Penrose-feltételekből következik, hogy $P := AA^+$ önadjungált idempotens, tehát ortogonális projekció. Mivel $AA^+A = A$, ez a projekció éppen az $\text{Im}(A)$ altérre vetít. Így

$$Ax^+ = AA^+b = Pb$$

a b vektor ortogonális vetülete $\text{Im}(A)$ -ra, ezért $b - Ax^+ \perp \text{Im}(A)$. Minden $x \in \mathbb{C}^n$ esetén $A(x - x^+) \in \text{Im}(A)$, tehát Pitagorasz tétele szerint

$$\|Ax - b\|_2^2 = \|A(x - x^+) + (Ax^+ - b)\|_2^2 = \|A(x - x^+)\|_2^2 + \|Ax^+ - b\|_2^2 \geq \|Ax^+ - b\|_2^2.$$

Ez igazolja, hogy x^+ minimalizálja a maradék normáját.

2. állítás. Az előző azonosságban egyenlőség pontosan akkor áll fenn, ha $A(x - x^+) = 0$, vagyis $x - x^+ \in \ker(A)$. Az SVD-alakból látszik, hogy $x^+ = A^+b \in \text{Im}(A^*)$, és az alaptétel szerint $\ker(A) = \text{Im}(A^*)^\perp$. Ezért $x^+ \perp (x - x^+)$, és ha $x \neq x^+$, akkor

$$\|x\|_2^2 = \|x^+ + (x - x^+)\|_2^2 = \|x^+\|_2^2 + \|x - x^+\|_2^2 > \|x^+\|_2^2.$$

Tehát x^+ a minimális maradékú megoldások között egyértelműen a legkisebb normájú. $\square \quad \square$

9.3. Megjegyzés.

1. Ha $Ax = b$ megoldható, akkor $x^+ = A^+b$ az origóhoz legközelebb lévő megoldás.
2. Ha $Ax = b$ nem megoldható (például túlhatározott rendszer), akkor x^+ a *reziduális norma* szerint legjobb közelítő megoldás, és ha több ilyen létezik, közülük a legkisebb normájú.
3. A fenti két esetben (túl- és alulhatározott teljes rangú) a szinguláris felbontás nem szükséges: elegendő megoldani a normálegyenleteket illetve a minimál-norma rendszert.

10. Legkisebb négyzetek módszere

Az alapfeladat

10.1. Definíció (A legkisebb négyzetek módszere). Adottak az $x_1, \dots, x_N \in [a, b]$ különböző alappontok és az $y_1, \dots, y_N \in \mathbb{R}$ függvény-, illetve mérési értékek. Keresünk $p_n \in P_n$ polinomot ($n + 1 \leq N$, általában $N \gg n$), amelyre

$$\sum_{i=1}^N (y_i - p_n(x_i))^2 \quad \text{minimális.}$$

A p_n polinomot *négyzetesen legjobban közelítő polinomnak* nevezzük.

A feladat tehát nem az, hogy $p_n(x_i) = y_i$ pontosan teljesüljön (ez csak $n = N - 1$ esetén érhető el), hanem az eltérések négyzetösszegét minimalizáljuk. Ez a statisztikában *lineáris regresszió*nak felel meg.

Mátrix alak

Írjuk fel $p_n(x) = a_n x^n + \dots + a_1 x + a_0$ alakban. Jelöljük:

$$A := \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^n \\ 1 & x_2 & x_2^2 & \cdots & x_2^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_N & x_N^2 & \cdots & x_N^n \end{pmatrix}_{N \times (n+1)}, \quad a := \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix}_{(n+1) \times 1}, \quad y := \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix}_{N \times 1}.$$

Ekkor a minimalizálandó mennyiség:

$$\|Aa - y\|_2^2 = \sum_{i=1}^N (p_n(x_i) - y_i)^2.$$

Ez pontosan a Tétel 9.2 kerete: az $Aa = y$ LER általában *túlhatározott és nem megoldható* (ha $N > n + 1$), de a Tétel szerint az általánosított megoldás $a^+ = A^+ y$ minimalizálja a négyzethibát.

Gauss-féle normálegyenletek

Ha A teljes oszloprangú ($\text{rang}(A) = n + 1$, ami teljesül, ha $N \geq n + 1$ és az x_i alappontok különbözők), akkor Tétel 8.5 alapján:

$$a^+ = (A^T A)^{-1} A^T y \iff A^T A a^+ = A^T y.$$

A szimmetrikus, $(n + 1) \times (n + 1)$ -es LER kifejtve:

$$\begin{pmatrix} N & \sum x_i & \cdots & \sum x_i^n \\ \sum x_i & \sum x_i^2 & \cdots & \sum x_i^{n+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum x_i^n & \sum x_i^{n+1} & \cdots & \sum x_i^{2n} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \\ \vdots \\ \sum x_i^n y_i \end{pmatrix}.$$

10.2. Megjegyzés.

1. Ha A teljes rangú, $A^T A$ mindig szimmetrikus és pozitív definit, tehát invertálható.


2. **Lineáris regresszió** ($n = 1$): A normálegyenletek:

$$\begin{pmatrix} N & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}.$$

Ha $\sum x_i = 0$ (például szimmetrikus alappontok), diagonális a rendszer: $a_0 = \frac{1}{N} \sum y_i$, $a_1 = \frac{\sum x_i y_i}{\sum x_i^2}$. Általánosán:

$$a_1 = \frac{N \sum x_i y_i - (\sum x_i)(\sum y_i)}{N \sum x_i^2 - (\sum x_i)^2}, \quad a_0 = \frac{\sum y_i - a_1 \sum x_i}{N}.$$

3. A négyzetesen legjobban közelítő p_1 egyenes mindig átmegy az adatok *átlagán* ($\bar{x}, \bar{y}$): ez éppen a normálegyenlet első sorából következik.
4. A közgazdászok és statisztikusok ezt *regressziós egyenesnek* hívják, és standardeszközként használják (statisztika, ökonometria).



4. ábra. Lineáris regresszió öt adatpontra. Az egyenes a legkisebb négyzetek módszerével illesztett $p_1(x) = a_1x + a_0$ polinom; a zöld függőleges szakaszok a reziduálisokat jelölik az adott x_i helyeken.

Szám példa: lineáris regresszió. Adottak a következő mérési adatok:

x_i	1	2	3	4	5
y_i	1,0	4,8	3,4	8,8	7,0

Számítsuk ki a legjobb lineáris közelítőt ($n = 1$)!

$N = 5$, $\sum x_i = 15$, $\sum y_i = 25,0$, $\sum x_i^2 = 55$, $\sum x_i y_i = 91,0$.

$$a_1 = \frac{5 \cdot 91,0 - 15 \cdot 25,0}{5 \cdot 55 - 225} = \frac{455,0 - 375,0}{275 - 225} = \frac{80,0}{50} = 1,600.$$

$$a_0 = \frac{25,0 - 1,600 \cdot 15}{5} = \frac{25,0 - 24,0}{5} = \frac{1,0}{5} = 0,200.$$

Így $p_1(x) \approx 1,600x + 0,200$.

Ellenőrzés: A reziduális norma: $\|Aa^+ - y\|_2^2 = \sum (p_1(x_i) - y_i)^2 = 11,44$.

Az adatok átlaga: $\bar{x} = 3$, $\bar{y} = 5,0$; valóban $p_1(3) = 4,8 + 0,2 = 5,0$. ✓

11. Az SVD alkalmazása: főkomponens-analízis (PCA)

Adatmátrix és központosítás

A főkomponens-analízis célja, hogy sokváltozós adatokat kevés, jól értelmezhető irány mentén írjunk le. Legyen

$$X \in \mathbb{R}^{N \times p},$$

ahol az N sor a mintákat, a p oszlop pedig a mért változókat jelöli. Az i -edik sor tehát egy p dimenziós adatpont: x_i^T .

A PCA előtt az adatokat központosítjuk. Jelölje

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \in \mathbb{R}^p$$

az oszloponkénti átlagvektort, és legyen $\mathbf{1} \in \mathbb{R}^N$ az egyesekből álló oszlopvektor. A központosított adatmátrix:

$$\tilde{X} = X - \mathbf{1}\bar{x}^T.$$

Ekkor $\tilde{X}$ minden oszlopának átlaga nulla.

Kapcsolat az SVD-vel

Vegyük a központosított adatmátrix redukált SVD-jét:

$$\tilde{X} = U\Sigma V^T,$$

ahol $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_r)$, $\sigma_1 \geq \dots \geq \sigma_r > 0$. Ebből

$$\tilde{X}^T \tilde{X} = V\Sigma^2 V^T.$$

Tehát a kovarianciamátrix

$$C = \frac{1}{N-1} \tilde{X}^T \tilde{X}$$

sajátvektorai éppen a V mátrix oszlopai, a sajátértékek pedig

$$\lambda_j = \frac{\sigma_j^2}{N-1}, \quad j = 1, \dots, r.$$

Vagyis a szinguláris értékek négyzetei azt mérik, mekkora variancia tartozik az egyes főirányokhoz.


11.1. Definíció (Főkomponensek). A központosított adatmátrix $\tilde{X} = U\Sigma V^T$ SVD-jében a V mátrix oszlopai, vagyis $v_1, \dots, v_r$, a *főirányok*. A j -edik főkomponens koordinátái:

$$\tilde{X}v_j = \sigma_j u_j$$

Az első k főkomponens az

$$Z_k = \tilde{X}V_k = U_k \Sigma_k \in \mathbb{R}^{N \times k}$$

mátrixot adja, ahol $V_k = [v_1 \mid \dots \mid v_k]$.



5. ábra. A PCA és a lineáris regresszió geometriai különbsége. Balra: a PCA az adatok átlagán átmenő főirányt keresi, és a pontokat merőlegesen vetíti erre az egyenesre. Jobbra: az $x_2 \sim x_1$ lineáris regresszió a függőleges reziduálisokat minimalizálja.

Geometriai interpretáció

A PCA és a lineáris regresszió geometriai feladata különböző. Lineáris regressziónál kijelölünk egy függő változót, például x_2 -t, és a függőleges hibák négyzetösszegét minimalizáljuk. PCA-nál nincs kitüntetett függő változó: olyan irányt keresünk, amelyre az adatok merőleges vetítési hibája minimális, illetve amely mentén a vetített adatok varianciája maximális.

Dimenziócsökkentés

Ha csak az első k főirányt tartjuk meg, akkor az adatokat p dimenzió helyett k dimenzióban ábrázoljuk:

$$x_i \mapsto \text{az } i\text{-edik sor } Z_k\text{-ban.}$$

Az ehhez tartozó visszavetített, közelítő adatmátrix:

$$\tilde{X}_k = Z_k V_k^T = U_k \Sigma_k V_k^T.$$

Ez pontosan az SVD levágott alakja, ezért az Eckart–Young-tétel szerint $\tilde{X}_k$ a legjobb rang- k közelítés Frobenius-normában.

A megtartott variancia aránya:

$$\frac{\sigma_1^2 + \dots + \sigma_k^2}{\sigma_1^2 + \dots + \sigma_r^2}.$$

Ha ez az arány közel van 1-hez, akkor az első k főkomponens kevés információvesztéssel írja le az adatokat.

11.2. Megjegyzés.

1. A PCA dimenziócsökkentésre használható: sok változót kevés főkomponenssel helyettesítünk.
2. Zajsűrűsként is értelmezhető: a kis szinguláris értékekhez tartozó irányokat gyakran elhagyjuk.
3. Két vagy három főkomponens megtartásával nagy dimenziós adatok szemléltethetők síkban vagy térben.

Összefoglalás

Numerikus integrálás

Formula	Típus	Hiba	Pontossági fok
Érintő $E(f)$	Ny(0)	$\frac{(b-a)^3}{24} f''(\eta)$	P_1
Trapéz $T(f)$	Z(1)	$-\frac{(b-a)^3}{12} f''(\eta)$	P_1
Simpson $S(f)$	Z(2)	$-\frac{(b-a)^5}{2880} f^{(4)}(\eta)$	P_3
Trapéz összetett $T_m(f)$	—	$-\frac{(b-a)^3}{12m^2} f''(\eta)$	$O(m^{-2})$
Simpson összetett $S_m(f)$	—	$-\frac{(b-a)^5}{180m^4} f^{(4)}(\eta)$	$O(m^{-4})$

Szinguláris felbontás és általánosított inverz

Fogalom	Tartalom
SVD	$A = UDV^*$, $D = \text{diag}(\sigma_1, \dots, \sigma_r, 0, \dots)$, U, V unitér
Szinguláris értékek	$\sigma_i = \sqrt{\lambda_i(A^*A)} > 0$
Eckart–Young	$A_k = \sum_{i=1}^k \sigma_i u_i v_i^*$ a legjobb rang- k közelítés
Moore–Penrose	$A^+ = VD^+U^*$ (4 ax. egyértelműen meghatározza)
Túlhatározott	$A^+ = (A^T A)^{-1} A^T$, normálegyenletek: $A^T A x = A^T y$
Alulhatározott	$A^+ = A^T (A A^T)^{-1}$, minimális norma
LNM	$\min \ Aa - y\ _2^2$: $a^+ = (A^T A)^{-1} A^T y$ (regresszió)
PCA	központosított adatmátrix SVD-je; főirányok: V oszlopai